

PatchCore 한국어 번역본

Towards Total Recall in Industrial Anomaly Detection | Roth et al., CVPR 2022

원문 기반 번역 정리. 방법명과 핵심 용어는 원문 표기를 병기했습니다.

초록

대규모 산업 제조에서 불량 부품을 발견하는 일은 핵심 과제다. 이 연구는 정상(무결함) 예시만으로 모델을 맞추는 cold-start 문제를 다룬다. 저자들은 정상 이미지의 patch feature를 최대한 대표적으로 보관하는 memory bank를 사용하는 PatchCore를 제안한다. PatchCore는 경쟁력 있는 추론 시간을 유지하면서 이미지 수준 탐지와 픽셀 수준 위치 추정에서 높은 성능을 낸다. MVTec AD에서 이미지 수준 AUROC는 최대 99.6%이며, 추가 산업 데이터셋과 적은 정상 샘플 조건에서도 경쟁력 있는 결과를 보인다.

1. 서론

산업 시각 검사에서는 정상 제품 영상은 얻기 쉽지만 가능한 모든 결함 변형을 정의하고 수집하는 일은 어렵고 비용이 크다. 따라서 이 과제는 학습 분포에서 나온 표본과 그 분포 밖 표본을 구별하는 out-of-distribution 탐지 또는 one-class classification으로 볼 수 있다. 결함은 얇은 굵금처럼 미세할 수도 있고 부품 누락처럼 구조적일 수도 있다. 기존 autoencoder, GAN, 비지도 적응 방법과 달리, 최근 접근은 ImageNet 사전학습 feature를 정상 사례와 비교해 높은 탐지 성능을 얻었다. 그러나 높은 계층의 ImageNet feature는 산업 환경의 의미와 잘 맞지 않을 수 있고, 비교 가능한 정상 문맥도 제한된다.

PatchCore의 핵심 아이디어

PatchCore는 테스트 시 활용하는 정상 정보를 최대화하고, ImageNet 클래스 편향을 줄이며, 빠른 추론을 유지하려 한다. 이미지 하나는 patch 하나만 이상이어도 이상으로 분류될 수 있다는 관찰에 따라, 지역적으로 집계한 중간 계층 patch feature를 사용한다. 중간 계층 feature는 해상도를 유지해 미세 결함에 유리하고, 이웃 feature 집계는 구조적 이상을 위한 공간 문맥을 보존한다.

2. 관련 연구

산업 이상 탐지는 정상 데이터 분포를 모델링해 재구성 오차로 결함을 찾는 방식, 정상 이미지와의 feature matching 방식, 적은 정상 표본을 다루는 방식으로 나뉜다. 재구성 기반 방법은 결함까지 정상처럼 복원할 위험이 있고, feature matching 방법은 어떤 계층을 저장하고 비교할지와 memory 크기가 성능 및 효율을 좌우한다. PatchCore는 중간 계층 feature, 지역 집계, 대표 coresets의 조합으로 이 문제를 다룬다.

3. 방법 - feature와 memory bank

정상 학습 이미지 집합에서 ImageNet 사전학습 backbone의 중간 계층 feature map을 추출하고, 각 공간 위치를 patch embedding으로 본다. 서로 다른 계층은 해상도를 맞춘 뒤 결합하며, 각 patch 주변 feature를 함께 모아 지역 문맥을 반영한다. 모든 정상 patch embedding을 저장하면 memory가 매우 커지므로, 저자들은 approximate greedy coresets을 사용한다. 이는 이미 고른 원소와 가장 멀리 떨어진 후보를 반복 선택하여, 중복을 줄이면서 정상 분포의 범위를 대표하는 부분집합을 만든다.

3. 방법 - 이상 점수

테스트 이미지에서도 동일한 patch embedding을 만들고, 각 patch에서 가장 가까운 정상 memory 항목까지의 거리를 구한다. 이미지 수준 이상 점수는 가장 큰 patch 거리로 정한다. 위치 추정 map은 모든 patch의 최근접 이웃 거리를 원래 공간 위치로 되돌려 만든다. 저자들은 가장 이상한 patch의 최근접 이웃 주변 normal memory와의 관계를 이용해 이미지 점수의 신뢰도를 재가중한다. 즉, normal patch 집합에서 멀리 떨어진 위치가 결함 후보가 된다.

4. 실험

주요 평가는 MVTec AD의 15개 범주에서 수행한다. 정상 학습 이미지와 결함 테스트 이미지를 사용하며, 이미지 수준 anomaly detection AUROC, 픽셀 수준 anomaly localization AUROC, PRO를 보고한다. 추가로 Magnetic Tile Defects와 few-shot 조건을 평가한다. 기본 구현은 ImageNet 사전학습 WideResNet-50의 layer2와 layer3 feature, approximate greedy coreset, 최근접 이웃 검색을 사용하며 FAISS로 검색을 가속한다. 재현 시에는 데이터셋 경로, backbone, 추출 계층, 입력 크기, coreset 비율, seed, GPU 및 FAISS 설정을 고정해야 한다.

4. 실험 - 결과와 해석

PatchCore는 MVTec AD에서 높은 이미지 수준 탐지와 픽셀 수준 위치 추정 성능을 보인다. 논문의 가장 큰 설정은 이미지 수준 AUROC 최대 99.6%를 보고한다. 결과는 중간 계층의 촘촘한 patch와 넓은 정상 memory가 결함 식별에 유리하며, coreset이 memory와 검색 시간을 줄이면서 성능 저하를 작게 유지함을 시사한다. 재현 수치는 하드웨어, 라이브러리, 전처리 차이로 달라질 수 있으므로 논문 수치와 자신의 결과를 같은 표에서 비교해야 한다.

5. 결론

PatchCore는 정상 이미지의 중간 계층 patch feature를 지역적으로 집계하고, 대표 normal memory bank와 최근접 이웃 비교를 통해 산업 이상을 탐지하고 위치를 추정한다. approximate greedy coreset은 대규모 patch memory를 실용적인 크기로 줄이는 핵심 장치다. 대상 데이터에 별도 학습하지 않고도 강한 성능을 보이지만, memory 크기, domain shift, 이미지 정렬 오차, 복잡한 배경과 다양한 객체 배치에서의 안정성은 후속 검토가 필요하다.

발표·재현 체크리스트

발표는 문제 설정(정상 데이터만 사용), 방법 흐름(backbone - patch embedding - local aggregation - coreset memory - nearest-neighbor scoring), 평가 지표(AUROC/PRO), 재현 계획 순으로 구성한다. 실험 표에는 논문 수치, 자신의 실행 수치, 실행 commit, script, raw CSV 경로를 함께 둔다. 수치가 다르면 데이터셋 구조, 전처리 크기, backbone 가중치, layer 선택, coreset 비율, seed, GPU/FAISS 설정을 순서대로 점검한다.

서지

Roth, Karsten, et al. "Towards Total Recall in Industrial Anomaly Detection." CVPR, 2022, pp. 14318-14328. 이 문서는 제공된 원문을 바탕으로 한 한국어 번역 정리본이다. 수식의 세부 표기, 표의 모든 수치, 그림은 원 논문 PDF를 함께 참조한다.